

Modelagem de Problemas utilizando Aprendizagem de Máquina: Análise comparativa de Algoritmos Simbólicos e Redes Neurais para Classificação de Sinais Vitais

Guilherme Peruci Felipe, Caique Ferraz Cornelio

Instituto de Informática – Universidade Tecnológica Federal do Paraná (UTFPR)
80.230-901 – Curitiba – PR – Brasil

guilhermefelippe@alunos.utfpr.edu.br, caiqueferraz@alunos.utfpr.edu.br

Abstract. *This paper presents a comparative analysis of symbolic and neural network approaches for vital sign classification using machine learning. Three distinct modeling techniques were used to achieve the result: (1) ID3 decision tree as representative symbolic learning method, (2) Random Forest as an ensemble symbolic approach, and (3) Neural Network as a subsymbolic paradigm. Using a clinical dataset of vital signs, this model was implemented addressing both performance and technical implications. The utilized methodology emphasizes hyperparameters optimization and overfitting prevention, analyzing the results and highlighting the advantages and limitations of each model. Results indicate clear performance differences and trade-offs among the evaluated approaches, guiding the appropriate selection of machine learning techniques for clinical scenarios involving human interaction.*

Resumo. *Este artigo apresenta uma análise comparativa de abordagens simbólicas e baseadas em redes neurais para a classificação de sinais vitais utilizando aprendizagem de máquina. Foram avaliadas três técnicas distintas de modelagem para alcançar os resultados: (1) Decision Tree ID3 como um método simbólico de aprendizagem, (2) Random Forest como método simbólico de ensemble, e (3) Redes Neurais como um paradigma sub simbólico. Utilizando um conjunto de dados clínicos de sinais vitais, cada técnica foi implementada buscando performance e implicações técnicas. A metodologia utilizada enfatiza a otimização de hiperparâmetros e prevenção de sobre-ajuste, analisando os resultados e destacando vantagens e limitações de cada modelo. Resultados indicam diferenças claras e compensações dentre as abordagens avaliadas, guiando a seleção apropriada de técnicas de aprendizagem de máquina para cenários clínicos envolvendo intervenções humanas.*

1. Introdução

A evolução da área da inteligência artificial tem impulsionado o desenvolvimento de metodologias sofisticadas para o tratamento e análise de dados em diversas áreas da sociedade. Entre sua vasta área de aplicação, destaca-se o aprendizado de máquina na área da saúde, especialmente no monitoramento e interpretação dos sinais vitais. Essa abordagem permite que sistemas automatizados aprendam a interpretar grandes volumes de dados clínicos para calcular um resultado esperado, oferecendo suporte à tomada de decisões médicas com maior precisão, agilidade e consistência.

O uso de algoritmos de aprendizagem de máquina na interpretação de sinais vitais possibilitam o alcance de um grande potencial de identificação precoce de condições críticas e preocupantes, além de facilitar a personalização de cuidados e redução de sobrecarga em ambientes hospitalares. Dentre as diversas técnicas disponíveis, destacam-se os métodos simbólicos, que oferecem uma estrutura lógica onde cada dado possui um simbolismo, e os métodos sub

simbólicos, como as redes neurais, que se sobressaem na modelagem de relações não lineares complexas.

Este artigo tem como objetivo apresentar os principais conceitos teóricos que fundamentam as metodologias utilizadas, bem como a análise dos procedimentos para a aplicação dos modelos implementados. Os resultados obtidos são analisados de forma crítica, considerando desempenho, robustez e aplicabilidade, além de serem discutidas questões éticas e sociais relacionadas à inserção desses sistemas em contextos clínicos. Por fim, são expostas as principais conclusões e análises dos resultados.

2. Fundamentação Teórica

2.1. Aprendizagem simbólica

A aprendizagem simbólica consiste em uma abordagem de modelagem que opera em um nível alto de compreensão lógica, no qual seres humanos são capazes de alcançar uma compreensão razoável da metodologia utilizada. As técnicas simbólicas baseiam-se em estruturas interpretáveis, como regras e árvores de decisão, sendo construídas com base na análise direta de atributos de dados de entrada e suas relações lógicas com o resultado esperado.

Dentre os exemplos mais populares de estrutura simbólicas, destacam-se os algoritmos ID3 e *Random Forest* (Floresta Aleatória), que utilizam de árvores de decisão e combinações de diversas árvores para formar modelos estruturados a partir de regras extraídas de dados.

2.1.1 ID3 (Decision Tree)

As *decision trees* (árvores de decisão) são modelos amplamente utilizados em aprendizado de máquina para resolver problemas de classificação e regressão. Sua estrutura se assemelha a uma árvore invertida, na qual cada nó interno representa uma decisão baseada em uma característica dos dados, e cada folha representa uma previsão final.

Uma *decision tree* é composta por três tipos principais de elementos:

1. Nó raiz (*root node*): É o primeiro nó da árvore, onde ocorre a primeira divisão dos dados com base na característica mais relevante.
2. Nós de decisão (*decision nodes*): São os nós intermediários, que analisam características específicas e decidem qual ramo seguir com base no maior ganho de informação.
3. Nós folha (*leaf nodes*): São os nós finais da árvore, onde se toma a decisão de classificação. Cada folha representa uma saída possível do modelo.

A construção da árvore segue uma lógica recursiva. Em cada nó, o algoritmo escolhe a característica que melhor separa os dados com base em medidas de impureza (como entropia ou índice de Gini). A cada divisão, o objetivo é formar subconjuntos o mais "puros" possível, isto é, contendo exemplos predominantemente de uma única classe.

2.1.2 Random Forest

A *Random Forest* é um algoritmo de aprendizado de máquina que pertence à categoria dos métodos de *ensemble*, ou seja, modelos que combinam múltiplos estimadores para melhorar o desempenho da previsão. Sua principal característica é a utilização de várias árvores de decisão

treinadas de forma independente, cujos resultados são combinados para gerar uma predição final mais robusta e precisa.

Cada árvore da “Floresta” é treinada a partir de uma amostra aleatória dos dados de treinamento, utilizando a técnica de *bootstrap*. Além disso, em cada divisão dentro das árvores, é considerado apenas um subconjunto aleatório das variáveis disponíveis, o que aumenta a diversidade entre as árvores.

Na fase de predição, cada árvore faz uma previsão individual. No caso de problemas de classificação, a *Random Forest* seleciona a classe preferida entre as árvores. Em tarefas de regressão, a predição final é a média dos valores previstos por cada árvore.

2.2. Aprendizagem sub simbólica

Diferentemente da aprendizagem simbólica, os métodos sub simbólicos baseiam-se em estruturas numéricas e padrões implícitos, os quais não oferecem uma explicação direta sobre o processo de decisão. Essa abordagem busca reconhecer padrões complexos e realizar conclusões com base em representações distribuídas, sem utilizar estruturas lógicas facilmente representáveis. Tais características a tornam mais ideal e adequada para lidar com dados que apresentam alto nível de complexidade, embora custe à interpretabilidade.

Entre os exemplos de tal paradigma, destacam-se as redes neurais, que operam por meio de múltiplas camadas de unidades interconectadas chamadas neurônios artificiais. Cada conexão entre neurônios possui um peso ajustado automaticamente durante o processo de treinamento, permitindo que o modelo aprenda a representar relações não lineares complexas, fazendo com que sejam especialmente eficazes em tarefas que envolvem grande volume de dados e padrões semi-perceptíveis.

2.2.1 MLP (Multi-layer-perceptron)

O MLP (*Multilayer Perceptron* ou Perceptron Multicamadas) é um modelo de aprendizado sub simbólico baseado em redes neurais formado por ao menos três camadas: uma de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio em uma camada está conectado aos neurônios da próxima camada por meio de pesos, que são ajustados durante o treinamento.

A informação flui da entrada até a saída (processo chamado de *forward propagation*), sendo transformada por funções de ativação (como ReLU ou sigmoid) que introduzem não-linearidade. O aprendizado ocorre com o algoritmo de retropropagação (*backpropagation*), que ajusta os pesos com base no erro da predição, minimizando uma função de perda.

3. Metodologia

3.1 Descrição do conjunto de dados

O conjunto de dados utilizado neste estudo é composto por registros clínicos com informações de sinais vitais coletados de vítimas de acidentes. Entre os atributos disponíveis estão a pressão sistólica e pressão diastólica, que não são diretamente utilizadas nas modelagens, pois servem para o cálculo da qualidade da pressão arterial (qPA), pulso (em batimentos por minuto), frequência respiratória (em respirações por minuto), gravidade (grau de severidade da situação) e classe (rótulo que representa a classe da gravidade) como base de dados.

Os alvo dos modelos são a gravidade e as classes, calculadas originalmente por fórmulas desconhecidas, a classe de gravidade é distribuída entre quatro níveis:

- 1 = crítico,
- 2 = instável,
- 3 = potencialmente estável,
- 4 = estável.

Dessa forma, o objetivo do trabalho é reconstruir, utilizando abordagens de aprendizado de máquina, tanto o valor contínuo da gravidade, como sua respectiva variável categórica.

3.2 Pré-processamento do conjunto de dados

Para as técnicas de aprendizado simbólico, ID3 e *Random Forest*, foram usados os parâmetros qPA, pulso e a frequência respiratória, então foi realizada a separação dos dados em conjuntos de treino e teste, utilizando 60% dos dados para o treinamento do modelo e os 40% restantes para teste, com o objetivo de testar o poder de generalização do modelo, a semente de aleatoriedade foi fixada para garantir a reprodutibilidade dos resultados.

Para a técnica de aprendizado sub simbólica, MLP, com aprendizado supervisionado o conjunto de dados foi enriquecido com a criação de variáveis derivadas, como a diferença de pressões (*P_diff*), a razão entre pressão e frequência cardíaca (*Pressure_per_pulse*), a razão de pressão para frequência cardíaca, e o índice respiratório (*Resp_index*), a razão entre qPA e respiração, resultando em seis atributos para treinamento, essas mudanças foram realizadas pelo fato de que o MLP pode perceber com maior facilidade relações complexas entre os dados quando a base de entradas é aumentada.

Os dados em seguida foram normalizados garantindo que as entradas possuíssem média zero e desvio padrão controlado, características que agilizam o processo de *backpropagation* e, por isso, também promovem um treinamento mais eficiente do modelo.

As saídas foram codificadas em formato *one-hot encoding*, viabilizando a utilização do MLP para classificação multiclasse. O conjunto de dados foi dividido em 70% para treino e 30% para teste com o mesmo objetivo das técnicas anteriores.

3.3 Estrutura

A definição da estrutura da *Decision Tree* ID3 e da *Random Forest* envolveu a variação dos principais hiperparâmetros da árvore como *min_samples_split* e *max_depth*. O parâmetro *min_samples_split* define o número mínimo de amostras necessário para dividir um nó interno, já *max_depth* limita a profundidade máxima da árvore, ambos foram alvos de análises de sensibilidade. Para cada valor de parâmetro, o modelo foi ajustado com os dados de treino, e as acurácias foram computadas para as duas variáveis, tanto para o conjunto de treino quanto para o de teste. Os resultados foram usados para analisar o comportamento do modelo quanto ao *overfitting* e *underfitting* em relação aos hiperparâmetros, assim possibilitando a escolha de uma estrutura ótima.

O MLP foi configurado em duas instâncias, uma de regressão que utiliza os dados iniciais para obter a gravidade, e uma de classificação que, com a gravidade, determina uma classe de gravidade, com diferentes quantidades de neurônios e camadas ocultas, explorando variações na arquitetura da rede para avaliar seu impacto no desempenho. Durante os testes, foram observadas variações no número de neurônios por camada, na taxa de aprendizado, no número de épocas e nas funções de ativação, com o objetivo de encontrar uma configuração que equilibrasse precisão e generalização, minimizando tanto o *overfitting* quanto o *underfitting*.

3.4 Técnicas de validação

Primeiramente, foi aplicada a validação cruzada *K-Fold*, com o objetivo de garantir maior confiabilidade na avaliação dos modelos, reduzindo a variabilidade causada por uma única divisão dos dados. Essa abordagem consiste em dividir o conjunto de dados em K partes (ou folds) e realizar K iterações de treinamento e teste, em que, a cada rodada, uma parte diferente é usada como teste enquanto as demais são usadas para treino, tornando possível estimar de forma mais robusta a capacidade de generalização dos classificadores, contribuindo para a escolha de configurações mais estáveis e menos suscetíveis ao sobreajuste.

Após essa etapa, foi realizada uma avaliação complementar por meio da separação dos dados em treino e teste. Essa abordagem possibilitou comparar o desempenho dos modelos em dados já vistos e não vistos durante o treinamento, oferecendo uma visão adicional sobre o comportamento dos algoritmos quanto à sua precisão e capacidade de generalização. Para isso foram usadas as métricas de Erro Quadrático Médio (RMSE), que quantifica a raiz do erro quadrático médio entre os valores previstos e os reais, acurácia, precisão, revocação (recall) e medida-F (*f-measure*). A acurácia avalia a proporção total de acertos; a precisão mede a proporção de previsões corretas entre as positivas; a revocação indica a capacidade do modelo em identificar corretamente os casos positivos; e a medida-F (*F1-score*) fornece uma média harmônica entre precisão e revocação, equilibrando as duas. Essas métricas complementares permitiram uma análise mais detalhada da performance dos modelos, considerando não apenas o número de acertos, mas também a qualidade e a relevância das previsões feitas.

4. Requisitos Funcionais e Não Funcionais

4.1. ID3

O modelo ID3 deve ser capaz de lidar com entradas clínicas discretizadas e gerar uma estrutura de árvore capaz de realizar classificações sobre a classe da gravidade com base em regras simples. Como requisitos não funcionais, destacam-se a alta interpretabilidade, o ID3 gera estruturas hierárquicas lógicas que permitem a clara compreensão dos critérios de decisão, sendo útil para validação por profissionais da saúde. Apresenta baixo custo computacional e tempo de treinamento reduzido, em contrapartida, sua capacidade de generalização é baixa, especialmente diante de conjuntos de dados com ruídos e padrões complexos.

4.2. Random Forest

No *Random Forest*, o modelo precisa ser capaz de operar sob múltiplas árvores de decisão e gerar uma saída consensual entre elas sobre a classe de gravidade. Isso exige um sistema que suporte treinamento paralelo de estimadores e integração eficiente dos resultados. Para os requisitos não funcionais, a principal vantagem dessa abordagem é a robustez e a maior capacidade de generalização frente a grande variação de dados para o treinamento, uma vez que combina várias árvores para produzir um resultado em conjunto. Embora mantenha certo grau de interpretabilidade, esta é menor em relação ao ID3, pois o modelo completo baseia-se em múltiplas árvores. Seu custo computacional é moderado, proporcional ao número de estimadores utilizados.

4.3. MLP

A arquitetura do *Multilayer Perceptron* (MLP) precisa aceitar entradas contínuas, normalizá-las, transformar a saída via *one-hot encoding* e ser capaz de ajustar pesos e vieses com base em *backpropagation* para obter tanto a gravidade quanto a classe dela. Nos requisitos não funcionais, a rede neural se destaca pela sua alta capacidade de generalização e desempenho

superior em padrões complexos. Contudo, exige mais recursos computacionais, tanto em tempo de treinamento quanto em processamento, o que pode ser uma grande limitação prática dependendo do ambiente de execução.

5. Resultados




Figura 1. Comparação de resultados entre os modelos.

(DT = Decision Tree, RF = Random Forest, MLP = MultiLayer Perceptron)

5.1. Resultados do ID3

A abordagem com ID3 apresentou desempenho satisfatório, embora inferior aos demais modelos avaliados. O algoritmo alcançou uma acurácia de 87,67% nos dados de teste, com precisão de 87,75%, revocação de 87,67% e *F1-score* (*F-measure*) de 87,69%. Esses valores indicam uma performance equilibrada, correspondente entre a capacidade de identificar corretamente as classes positivas e a proporção de acertos nas previsões.

Apesar de seu desempenho consistente, o ID3 demonstrou menor capacidade de generalização em comparação com os outros métodos utilizados. O modelo teve uma diferença perceptível entre os resultados em treino e teste, sugerindo um possível início de sobreajuste. Ainda assim, o desempenho se manteve dentro de um intervalo considerado confiável para aplicações em cenários reais com baixa complexidade de padrões.

Seu principal destaque está na transparência do processo de decisão, fator relevante em ambientes clínicos, onde a interpretabilidade das previsões é um diferencial para a validação por especialistas da saúde. Ademais, o baixo custo computacional e o tempo reduzido de execução reforçam sua viabilidade em contextos com recursos limitados.

Portanto, mesmo não sendo o modelo mais preciso, o ID3 mantém sua relevância por oferecer uma solução simples, interpretável e eficiente, especialmente adequada para aplicações onde a confiança na lógica de decisão é mais importante do que a precisão máxima do resultado.

5.2. Resultados da Random Forest

A abordagem *Random Forest* apresentou desempenho superior à abordagem ID3, alcançando uma acurácia de 89,83% nos dados de teste. Além disso, obteve precisão de 89,98%, revocação (*recall*) de 89,83% e *F1-score* (*F-measure*) de 89,52%, demonstrando um modelo equilibrado e com alta capacidade de generalização.

Esse desempenho pode ser atribuído ao uso de múltiplas árvores de decisão treinadas de forma independente e combinadas por votação, o que reduz a variância do modelo e contribui para a robustez da predição. A validação cruzada também demonstrou consistência nos resultados, com baixa variação entre os folds, indicando estabilidade frente a diferentes subconjuntos de dados.

Apesar da perda de interpretabilidade em relação ao ID3, a *Random Forest* compensa essa limitação com maior confiabilidade e precisão, tornando-se uma alternativa eficaz para aplicações clínicas que demandam robustez na tomada de decisão, mesmo em cenários com dados ruidosos.

5.3. Resultados dos MLPs

A modelagem com MLPs foi a que apresentou o melhor desempenho geral entre as abordagens testadas. Para a tarefa de classificação das classes de gravidade, o modelo atingiu uma acurácia de 91,33%, com precisão de 91,86%, revocação de 91,33% e *F1-score* (*F-measure*) de 91,35%. Esses resultados demonstram um modelo altamente eficiente, com desempenho superior em todas as métricas avaliadas.

O equilíbrio entre precisão e revocação mostra que o MLP não apenas acerta com frequência, mas também mantém uma boa capacidade de identificar corretamente os casos positivos, sem perda significativa de sensibilidade ou especificidade. Esse desempenho é especialmente relevante em contextos clínicos, onde erros de classificação podem ter consequências importantes.

Em contrapartida, o custo computacional do MLP foi o mais elevado entre os modelos testados, tanto em tempo de treinamento quanto em necessidade de processamento. Além disso, por ser uma abordagem sub simbólica, sua interpretabilidade é limitada, dificultando a explicação direta dos critérios de decisão.

Ainda assim, seu alto poder de generalização e capacidade de capturar padrões complexos tornam os MLPs uma das escolhas mais promissoras para tarefas envolvendo sinais vitais, especialmente em aplicações onde a precisão é mais crítica do que a transparência da decisão.

5.4. Desempenho Geral

Com base nas métricas de avaliação (acurácia, precisão, *recall* e *F1-score*), o modelo de MLP apresentou o melhor desempenho geral, com destaque para sua acurácia de 91,33% e *F1-score* de 91,35%, superando tanto a *Random Forest* (89,83% de acurácia) quanto o ID3 (87,67% de acurácia). Esse resultado confirma a eficácia da abordagem sub simbólica em capturar padrões não lineares e complexos presentes nos dados clínicos.

5.5. Robustez

A *Random Forest* se destacou como o modelo mais robusto frente à variabilidade dos dados. Sua estrutura baseada em múltiplas árvores promoveu uma performance consistente com baixa sensibilidade a ruídos e flutuações no conjunto de treino, apresentando desvio padrão reduzido na validação cruzada. O ID3, por outro lado, foi mais sensível ao *overfitting*, enquanto o MLP, embora altamente performático, mostrou maior dependência de uma configuração otimizada para manter estabilidade.

5.6. Tempo de Treinamento

O ID3 teve o menor tempo de treinamento, sendo o modelo mais leve computacionalmente. A *Random Forest* apresentou tempo de treinamento moderado, proporcional ao número de estimadores utilizados. O MLP foi o modelo com maior demanda computacional, exigindo mais tempo de treinamento, principalmente devido à necessidade de ajuste de múltiplos hiperparâmetros e ao processo de *backpropagation*.

5.7. Capacidade de Generalização

Em termos de generalização, tanto o MLP quanto a *Random Forest* demonstraram excelente desempenho em dados não vistos, com pequena diferença entre acurácia de treino e teste. Isso indica que ambos os modelos foram eficazes em evitar o sobreajuste. O ID3, embora eficiente em cenários simples, mostrou limitação em generalizar para dados mais complexos, sendo mais suscetível ao *overfitting* com estruturas muito profundas ou ao *underfitting* quando excessivamente restrito.

6. Discussão sobre Impactos Humanos

A aplicação de modelos de aprendizagem de máquina no contexto medicinal e clínico, especialmente em áreas sensíveis como a análise de sinais vitais, levanta variadas reflexões sobre impactos humanos. Uma das principais considerações diz respeito à ética na tomada de decisões dos algoritmos. Embora modelos simbólicos como o ID3 e *Random Forest* ofereçam maior interpretabilidade, facilitando a compreensão e validação por profissionais de saúde, modelos sub simbólicos, como as redes neurais, apresentam decisões de difícil explicação e compreensão, o que pode comprometer a confiança de profissionais da área médica e seus respectivos pacientes nos resultados obtidos.

Outro dilema importante são os riscos relacionados à tendência nos dados utilizados para o treinamento dos modelos. Caso os dados históricos reflitam padrões de tratamento discriminatórios ou inconsistentes, os modelos de aprendizagem tendem a repetir esses padrões, o que pode resultar em favorecimentos ou desfavorecimentos de determinados grupos de pacientes. Portanto, a transparência dos modelos torna-se um elemento essencial para garantir justiça e igualdade perante à essa tecnologia.

Além disso, outro ponto de extrema importância é a privacidade. Como os dados utilizados envolvem informações sensíveis sobre o estado de saúde de indivíduos, é fundamental garantir a anonimidade e a segurança desses registros, respeitando legislações como a Lei Geral de Proteção de Dados (LGPD). A supervisão humana, aliada a políticas bem estabelecidas de uso dos sistemas, é indispensável para que os modelos de aprendizado de máquina atuem como ferramentas de apoio para a prática clínica ética e responsável.

7. Conclusão comparativa

A partir das análises conduzidas neste estudo, é observado que a aplicação de modelos de aprendizagem de máquina na classificação de sinais vitais permite alcançar níveis altos de desempenho, desde que haja uma escolha criteriosa da abordagem. Mediante a avaliação específica de cada modelo, é de grande percepção que não há uma solução universal para esse problema, mas sim ferramentas que respondem de forma diferente às necessidades específicas situacionais:

- O ID3 oferece alta interpretabilidade e baixo custo computacional, ideal para aplicações em que a explicação da decisão é prioritária, mesmo com desempenho inferior.
- A *Random Forest* equilibra robustez, desempenho e interpretabilidade parcial, sendo uma excelente escolha quando se busca confiança e estabilidade sem grande complexidade computacional.
- O MLP, embora menos interpretável e mais custoso, entrega o melhor desempenho geral, sendo recomendado em situações críticas onde a precisão é mais importante que transparência.

Essa comparação ressalta a importância de alinhar a escolha do modelo com os requisitos práticos.

Além da comparação técnica, foram discutidas questões éticas e sociais relevantes para o contexto de aplicabilidade de técnicas de aprendizado de máquina em áreas sensíveis como a área clínica e medicinal. Temas como justiça algorítmica, privacidade dos dados e transparência na tomada de decisão são centrais para que essas tecnologias sejam adotadas de forma segura, ética e responsável.

8. Referências

- Ng, A. (2023) *Machine Learning Specialization – Stanford University & DeepLearning.AI*. Disponível em: <https://www.deeplearning.ai/courses/machine-learning-specialization/>
- Felippe, G.P. & Cornelio, C.F. (2025) *Study to compare different technics performances on a vital signals dataset* <https://github.com/gUI-pe/classification-and-regression-study>
- Geron, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. 2nd ed. O'Reilly, 2019
- Scikit-learn Documentation (2025) <https://scikit-learn.org/>
- Ilkou, E. & Koutraki, M. *Symbolic Vs Sub-symbolic AI Methods: Friends or Enemies?* Leibniz University of Hannover, Welfengarten 1, 30167 Hannover, Germany <https://ceur-ws.org/Vol-2699/paper06.pdf>

9. Horas investidas no trabalho

Ambos autores participaram do estudo de maneira total e em conjunto, utilizando 19 horas cada.